Y36XML – Technologie XML

Přednáší:

Irena Mlýnková (mlynkova@ksi.mff.cuni.cz)

Martin Nečaský (necasky@ksi.mff.cuni.cz)

ZS 2009

Stránka přednášky:

http://www.ksi.mff.cuni.cz/~mlynkova/Y36XML/

Osnova předmětu

- ☐ Úvod do principů formátu XML, přehled XML technologií, jazyk DTD
- ☐ Datové modely XML, rozhraní DOM a SAX
- Úvod do jazyka XPath
- ☐ Úvod do jazyka XSLT
- ☐ XPath 2.0, XSLT 2.0
- Úvod do jazyka XML Schema
- Pokročilé rysy jazyka XML Schema
- Přehled standardních XML formátů
- Úvod do jazyka XQuery
- Pokročilé rysy jazyka XQuery, XQuery Update
- Úvod do XML databází, nativní XML databáze, číslovací schémata, structural join
- Relační databáze s XML rozšířením, SQL/XML

Jmenné prostory

Jmenné prostory

- Problém: Nutnost rozlišení elementů a atributů se shodnými jmény v případech, kdy by mohlo dojít ke konfliktům
 - Aplikace potřebuje vědět, které elementy/atributy má zpracovat
 - př. název knihy vs. název firmy
- Myšlenka: jméno elementu/atributu = jmenný prostor + lokální jméno
 - Jmenný prostor se identifikuje pomocí URI
 - Obvykle se deklaruje pomocí DTD nebo XML Schema (častější)
- □ URI je příliš dlouhé → zkrácený zápis
 - Deklarace jmenného prostoru = prefix + URI
 - Kvalifikované jméno (QName) = prefix + lokální jméno elementu/atributu

Př. jmenné prostory

```
<cenik:nabidka</pre>
    xmlns:cenik="http://www.ecena.cz/e-cenik"
    xmlns:bib="http://www.book.org/bibliography">
  <cenik:polozka cenik:dph="22%">
    <cenik:nazev>
      <br/>bib:book>
        <br/>
<bib:author>Jiri Kosek</bib:author>
        <br/>
<bib:title>HTML - tvorba dokonalych WWW
stranek</bib:title>
      </bib:book>
    </cenik:nazev>
    <cenik:cena mena="CZK">259</cenik:cena>
  </cenik:polozka>
</cenik:nabidka>
```

Př. implicitní jmenný prostor

```
<nabidka
    xmlns="http://www.ecena.cz/e-cenik"
    xmlns:bib="http://www.book.org/bibliography">
  <polozka cenik:dph="22%">
    <nazev>
      <br/>bib:book>
        <br/>
<bib:author>Jiri Kosek</bib:author>
        <br/>
<bib:title>HTML - tvorba dokonalych WWW
stranek</bib:title>
      </bib:book>
    </nazev>
    <cena mena="CZK">259</cena>
  </polozka>
</nabidka>
```

Jmenný prostor

- Kolekce identifikátorů neobsahující duplikace
- Jmenný prostor sestává z disjunktních množin:
 - Oddíl jmen elementů (all element partition)
 - Unikátní jméno je dáno identifikátorem prostoru a jménem elementu
 - Oddíl globálních atributů (global attribute partition)
 - Unikátní jméno je dáno identifikátorem prostoru a jménem atributu
 - Oddíl za každý element (per element type partitions)
 - Unikátní jméno je dáno identifikátorem prostoru, jménem elementu a lokálním jménem atributu

Př. části jmenných prostorů

```
<nabidka
    xmlns="http://www.ecena.cz/e-cenik"
    xmlns:bib="http://www.book.org/bibliography">
  <polozka cenik:dph="22%">
    <nazev>
      <br/>
<br/>
bib:book>
        <bib:author>Jiri Kosek</bib:author>
        <bib:title xml:lang="cs">HTML - tvorba
dokonalych WWW stranek</bib:title>
      </bib:book>
    </nazev>
    <cena mena="CZK">259</cena>
  </polozka>
</nabidka>
```

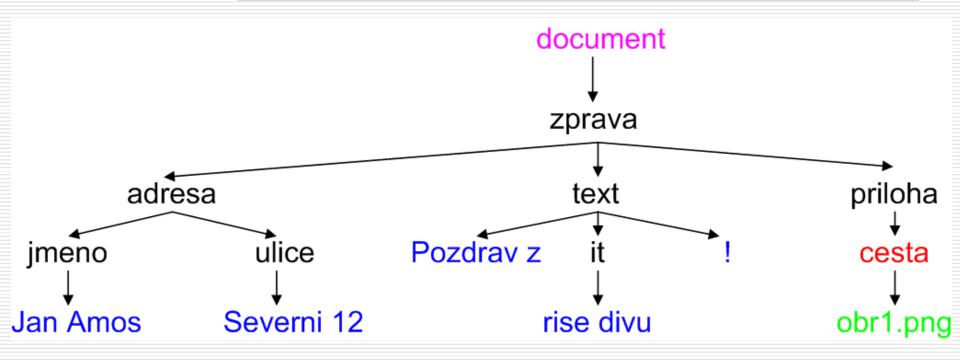
Jmenný prostor XML

- Každý XML dokument má přiřazený jmenný prostor XML
 - URI: http://www.w3.org/XML/1998/namespace
 - Prefix: xml
 - Není třeba jej deklarovat
- Obsahuje globální atributy:
 - xml:lang jazyk obsahu elementu
 - ☐ Hodnoty jsou dány normou
 - xml:space zpracování bílých znaků aplikací
 - □ preserve = zachovat
 - □ default = použít nastavení aplikace
 - Obvykle nahradí vícenásobné mezery jednou
 - xml:id jednoznačný identifikátor (typu ID)
 - xml:base určení základního URI, další relativně k němu

Datový model XML

XML Infoset

- □ Správně strukturovaný XML dokument → hierarchická stromová struktura = XML Infoset
 - Abstraktní datový model XML dat
- Information set = množina informací
- Information item = uzel stromu
 - Typy položek: Dokument, element, atribut, řetězec znaků, instrukce pro zpracování, komentář, notace, DTD deklarace, ...
 - Vlastnosti položek: jméno, rodiče, potomci, obsah, ...
- Je využíván v dalších standardech
- DTD může "modifikovat" infoset
 - Př. defaultní nebo fixní hodnoty atributů



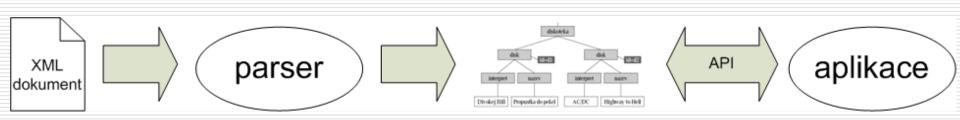
Post Schema Validation Infoset (PSVI)

- Otypovaný infoset
- Vznikne přiřazením datových typů na základě validace oproti schématu
 - Můžeme pracovat přímo s typovými hodnotami
 - Bez PSVI máme jen textové řetězce
- Využití: v dotazovacích jazycích (XQuery, XPath)
 - Např. máme funkce specifické pro řetězce, čísla, datumy,

XML parsery

XML parsery

- Problém: XML data chceme zpracovávat programově načítat
- - Pracné, nepohodlné, neefektivní
- Řešení: Při zpracování nás zajímá co je element, atribut, text, komentář, ... → zajímá nás infoset XML dokumentu
- □ Parser = SW, který umí přes vhodné rozhraní poskytovat infoset dokumentu aplikaci

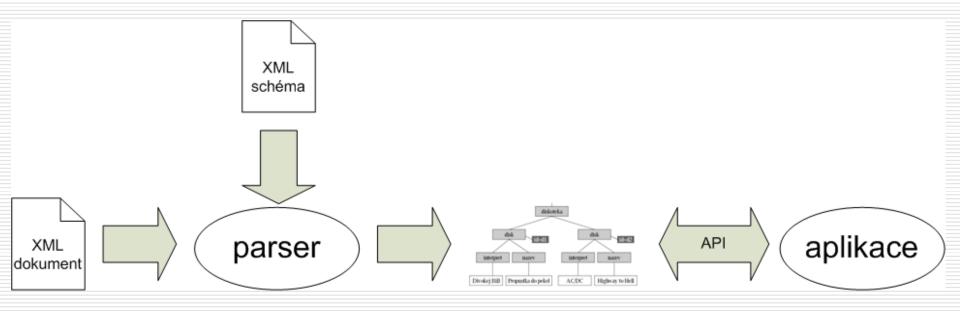


Typy parserů (1)

- Sekvenční
 - Rychlé, paměťově nenáročné
 - Jeden lineární průchod
- Stromová reprezentace
 - Celý dokument je načten v paměti
 - Opakovaný a nesekvenční průchod
 - Paměťově náročné, neefektivní
- Push vs. pull parser
 - Proud událostí vs. čtení na vyžádání

Typy parserů (2)

- Validující × nevalidující
 - Umí kontrolovat validitu dokumentu oproti schématu



□ S/bez podpory PSVI

Rozhraní SAX

SAX

- ☐ SAX = Simple API for XML
- □ Načtení části dokumentu = událost
 - Můžeme definovat obsluhu
- Hlavní události:

Atributy jsou součástí parametrů startElement ()

Java: Interface ContentHandler

void startDocument () void endDocument () void startElement (String uri, String localName, String qName, Attributes atts) void endElement (String uri, String localName, String qName) void characters (char[] ch, int start, int length) void processingInstruction (String target, String data) void ignorableWhitespace (char[] ch, int start, int length) void startPrefixMapping (String prefix, String uri) void endPrefixMapping (String prefix) void skippedEntity (String name) void setDocumentLocator (Locator locator)

ContentHandler: startElement ()

- String uri
 - URI jmenného prostoru
- ☐ String localName
 - Lokální jméno
- String qName
 - Kvalifikované jméno
- Attributes atts

```
for (int i = 0; i < atts.getLength (); i++ ) {
   System.out.println (atts.getQName (i));
   System.out.println (atts.getValue (i));
}</pre>
```

Interface Attributes (1)

- ☐ int getLength ()
 - Počet atributů v seznamu
- ☐ int getIndex (String qName)
 - Index atributu s daným (kvalifikovaným) jménem
- ☐ int getIndex (String uri, String localName)
 - Index atributu s daným lokálním jménem a URI jmenného prostoru
- □ String getLocalName (int index)
 - Lokální jméno atributu s daným indexem
- ☐ String getQName (int index)
 - Kvalifikované jméno atributu s daným indexem
- ☐ String getURI (int index)
 - URI atributu s daným indexem

Interface Attributes (2)

- ☐ String getType (int index)
 - Typ atributu s daným indexem
- String getType (String qName)
 - Typ atributu s daným (kvalifikovaným) jménem
- String getType (String uri, String localName)
 - Typ atributu s daným lokálním jménem a URI jmenného prostoru
- ☐ String getValue (int index)
 - Hodnota atributu s daným indexem
- String getValue (String qName)
 - Hodnota atributu s daným (kvalifikovaným) jménem
- ☐ String getValue (String uri, String localName)
 - Hodnota atributu s daným lokálním jménem a URI jmenného prostoru

CDATA
ID
IDREF
IDREFS
NMTOKEN

NMTOKENS

ENTITY

ENTITIES

NOTATION

ContentHandler: characters ()

- SAX parser může znaková data dávkovat libovolně → nelze počítat s tím, že je celý text doručen v rámci jednoho volání
- char[] ch
 - Pole v němž jsou znaky uloženy
- int start
 - Počáteční pozice znaků
- int length
 - Počet znaků

ContentHandler: ignorableWhitespace ()

- ☐ Ignorované bílé znaky
- char[] ch
 - Pole v němž jsou znaky uloženy
- int start
 - Počáteční pozice znaků
- int length
 - Počet znaků

ContentHandler: setDocumentLocator ()

```
class MujContentHandler implements ContentHandler {
   Locator locator;

public void setDocumentLocator (Locator locator) {
   this.locator = locator;
   }
   ...
```

- ☐ Zacílení místa v dokumentu, kde vznikla událost
- Interface Locator
 - int getColumnNumber () číslo sloupce
 - int getLineNumber () číslo řádku
 - String getPublicId () veřejný identifikátor dokumentu
 - String getSystemId () systémový identifikátor dokumentu

Inicializace zpracování

```
// Vytvorime instanci parseru
XMLReader parser = XMLReaderFactory.createXMLReader ();

// Vytvorime vstupni proud XML dat
InputSource source = new InputSource ("mujDokument.xml");

// Nastavime vlastni content handler pro obsluhu udalosti
parser.setContentHandler (new MujContentHandler ());

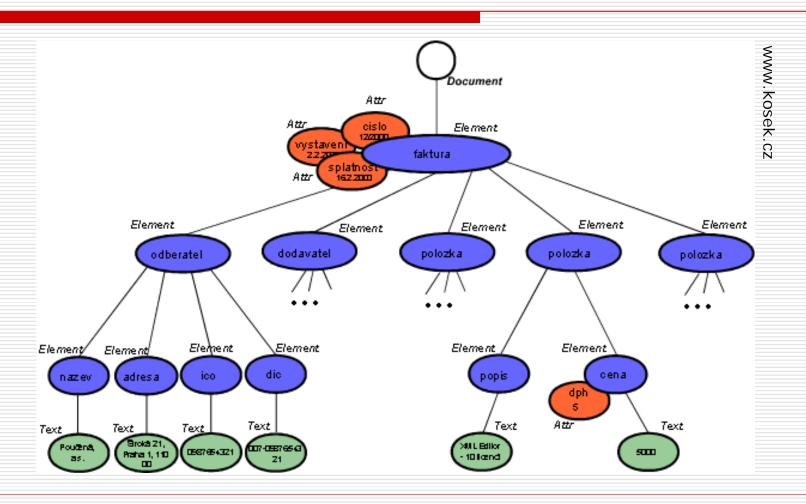
// Zpracujeme vstupni proud XML dat
parser.parse (source);
```

Rozhraní DOM

DOM

- □ DOM = Document Object Model
- Standard W3C
 - Verze: DOM1, DOM2 a DOM3
 - http://www.w3.org/DOM/DOMTR
- Celý dokument je načten do paměti
- Stromová reprezentace
- Jednotlivé uzly stromu jsou reprezentovány objekty
 - Dokument, fragment dokumentu, deklarace DTD, element, atribut, text, sekce CDATA, komentář, entita, reference na entitu, notace, instrukce pro zpracování
 - Metody objektů jsou dány specifikací DOM
 - Potomci objektů jsou dány XML Infosetem

Př. DOM strom



Java: Vybudování DOM stromu

```
// DocumentBuilderFactory vytvari DOM parsery
DocumentBuilderFactory dbf =
  documentBuilderFactory.newInstance ();
// nebudeme validovat
dbf.setValidating (false);
// vytvorime si DOM parser
DocumentBuilder builder =
  dbf.newDocumentBuilder ("mujDokument.xml");
// parser zpracuje soubor a vytvori strom DOM objektu
Document doc = builder.parse ();
// zpracujeme DOM strom
processTree (doc);
                           Document doc
```

Java: Uložení DOM stromu

```
// TransformerFactory vytvari serializatory DOM stromu
TransformerFactory tf = TransformerFactory.newInstance ();
// Transformer serializuje DOM stromy
Transformer writer = tf.newTransformer ():
// nastavime kodovani
writer.setOutputProperty
  (OutputKeys.ENCODING, "windows-1250");
// spustime transformaci DOM stromu do XML dokumentu
writer transform
  (new DOMSource (doc),
   new StreamResult (new File ("vystupniDokument.xml")));
```

Třídy v Javě (1)

- Node základ pro další rozhraní reprezentující uzly DOM stromu:
 - Document potomci: Element (maximálně jeden),
 ProcessingInstruction, Comment, DocumentType (maximálně jeden)
 - DocumentFragment potomci: Element,
 ProcessingInstruction, Comment, Text, CDATASection,
 EntityReference
 - Element potomci: Element, Text, Comment,
 ProcessingInstruction, CDATASection, EntityReference
 - Attr potomci: Text, EntityReference
 - Text bez potomků
 - CharacterData bez potomků

Třídy v Javě (2)

- ProcessingInstruction bez potomků
- Comment bez potomků
- CDATASection bez potomků
- Entity potomci: Element, ProcessingInstruction, Comment, Text, CDATASection, EntityReference
- EntityReference potomci: Element,
 ProcessingInstruction, Comment, Text, CDATASection,
 EntityReference
- Notation bez potomků
- DocumentType bez potomků

Interface Node (1)

String getNodeName () short getNodeType () String getNodeValue () String getBaseURI () String getPrefix () void setPrefix (String prefix) String getLocalName () String getNamespaceURI () String lookupNamespaceURI (String prefix) String lookupPrefix (String namespaceURI) boolean isDefaultNamespace (String namespaceURI) boolean hasAttributes () П boolean hasChildNodes ()

Interface Node (2)

- □ Node getParentNode ()□ Node getPreviousSibling ()
- □ Node getNextSibling ()
- □ NodeList getChildNodes ()
- □ Node getFirstChild ()
- □ Node getLastChild ()
- □ NamedNodeMap getAttributes ()
- ☐ String getTextContent ()
- □ Document getOwnerDocument ()
 - Vrací Document asociovaný s uzlem
- Node removeChild (Node oldChild)
- Node replaceChild (Node newChild, Node oldChild)
- Node appendChild (Node newChild)
- □ Node insertBefore (Node newChild, Node refChild)

Interface Node (3)

- Node cloneNode (boolean deep)
- □ void setNodeValue (String nodeValue)
- void setTextContent (String textContent)
- □ void normalize ()
 - Normalizuje všechny textové poduzly, tj. sloučí sousední textové uzly a eliminuje prázdné
- □ boolean isEqualNode (Node arg)
- □ boolean isSameNode (Node other)
- □ short compareDocumentPosition (Node other)
 - Porovná pozice uzlů v dokumentu

Interface Node (4)

- ☐ Object getUserData (String key)
 - Vrací objekt s daným klíčem asociovaný s uzlem
- Object setUserData (String key, Object data, UserDataHandler handler)
 - Asociuje objekt s daným klíčem s uzlem
- ☐ Object getFeature (String feature, String version)
 - Vrací objekt implementující danou verzi dané vlastnosti
- □ boolean isSupported (String feature, String version)
 - Testuje jestli implementace podporuje danou verzi dané vlastnosti

| Interface | nodeName | nodeValue | attributes |
|----------------------------|--------------------------------------|--|-------------------|
| Attr | jako Attr.name | jako Attr.value | null |
| CDATA- Section | "#cdata-section" | jako CharacterData.data, obsah sekce CDATA | null |
| Comment | "#comment" | jako CharacterData.data, obsah komentáře | null |
| Document | "#document" | null | null |
| Document- Fragment | "#document-fragment" | null | null |
| Document- Type | jako DocumentType.name | null | null |
| Element | jako Element.tagName | null | Named- NodeMap |
| Entity | jméno entity | null | null |
| Entity- Reference | jméno referencované entity | null | null |
| Notation | jméno notace | null | null |
| Processing- Instruction | jako ProcessingInstruction.target | jako ProcessingInstruction.data | null |
| Text | "#text" | jako CharacterData.data, obsah textového uzlu | null |

Př. dětské uzly vs. atributy

```
for (Node child = n.getFirstChild();
    child != null;
    child = child.getNextSibling())
    {
    processChildNode(child);
    }
}
```

```
NamedNodeMap atts = n.getAttributes();
for (int i = 0; i < atts.getLength(); i++)
    {
    Node att = atts.item(i);
    processAttribute(att);
    }</pre>
```

Interface Document (1)

Attr createAttribute (String name) Attr createAttributeNS (String namespaceURI, String qualifiedName) CDATASection createCDATASection (String data) Comment createComment (String data) DocumentFragment createDocumentFragment () П Element createElement (String tagName) Element createElementNS (String namespaceURI, String qualifiedName) EntityReference createEntityReference (String name) ProcessingInstruction createProcessingInstruction (String target, String data) Text createTextNode (String data) О Element getElementByld (String elementId) Vrací element s danou hodnotou atributu typu ID NodeList getElementsByTagName (String tagname) NodeList getElementsByTagNameNS (String namespaceURI, String localName)

Interface Document (2)

- □ Element getDocumentElement ()□ DocumentType getDoctype ()
- □ Node renameNode (Node n, String namespaceURI, String qualifiedName)
- □ Node adoptNode (Node source)
 - Připojí daný uzel do aktuálního dokumentu
- □ Node importNode (Node importedNode, boolean deep)
 - Importuje daný uzel do aktuálního dokumentu, tj. vytvoří jeho kopii
- String getInputEncoding ()
 - Vrací kódování použité při parsingu
- ☐ String getXmlEncoding ()
- □ DOMImplementation getImplementation ()
 - Vrací implementaci (DOMImplementation), k níž přísluší dokument
- □ DOMConfiguration getDomConfig ()
 - Vrací konfiguraci pro normalizaci různých typů uzlů

Interface Document (3)

- □ boolean getXmlStandalone ()
 □ String getDocumentURI ()
 □ void setXmlStandalone (boolean xmlStandalone)
 □ void setXmlVersion (String xmlVersion)
 □ void setDocumentURI (String documentURI)
 □ void normalizeDocument ()
 Normalizuje XML dokument, tj. nahradí všechny referecne na entity a normalizuje textové hodnoty
- □ boolean getStrictErrorChecking ()
 - Zjišťuje zda je kontrola chyb daná specifikací nebo závislá na implementaci
- □ void setStrictErrorChecking (boolean strictErrorChecking)
 - Určuje zda je kontrola chyb daná specifikací nebo závislá na implementaci

Interface Element (1)

- ☐ String getTagName ()
 - Jméno elementu
- □ NodeList getElementsByTagName (String name)
 - Seznam (NodeList) všech potomků daného jména
- NodeList getElementsByTagNameNS (String namespaceURI, String localName)
 - Seznam (NodeList) všech potomků daného lokálního jména a URI
- String getAttribute (String name)
 - Hodnota atributu daného jména
- ☐ Attr getAttributeNode (String name)
 - Atributový uzel daného jména
- ☐ Attr getAttributeNodeNS (String namespaceURI, String localName)
 - Atributový uzel daného lokálního jména a URI
- ☐ String getAttributeNS (String namespaceURI, String localName)
 - Hodnota atributu daného lokálního jména a URI

Interface Element (2)

- □ boolean hasAttribute (String name)
 - true = element má atribut daného jména
- boolean hasAttributeNS (String namespaceURI, String localName)
 - true = element má atribut daného lokálního jména a URI
- □ void removeAttribute (String name)
 - Odstraní atribut daného jména
- ☐ Attr removeAttributeNode (Attr oldAttr)
 - Odstraní atributový uzel
- void removeAttributeNS (String namespaceURI, String localName)
 - Odstraní atribut daného lokálního jména a URI
- □ TypeInfo getSchemaTypeInfo ()
 - Typová informace pro daný element

Interface Element (3)

- □ void setAttribute (String name, String value)
 - Přidá nový atribut
- Attr setAttributeNode (Attr newAttr)
 - Přidá nový atribut
- Attr setAttributeNodeNS (Attr newAttr)
 - Přidá nový atribut
- void setAttributeNS (String namespaceURI, String qualifiedName, String value)
 - Přidá nový atribut
- □ void setIdAttribute (String name, boolean isId)
 - Zmena datového typu atributu z/na ID
- □ void setIdAttributeNode (Attr idAttr, boolean isId)
 - Zmena datového typu atributu z/na ID
- void setIdAttributeNS (String namespaceURI, String localName, boolean isId)
 - Zmena datového typu atributu z/na ID

Př. vytvoření elementu

```
public Node createEmployee(Document document) {
  Element firstName = document.createElement("FirstName");
  firstName.appendChild(document.createTextNode("Shawn"));
  Element lastName = document.createElement("LastName");
  lastName.appendChild(document.createTextNode("Michaels"));
  Attr genderAttribute = document.createAttribute("gender");
  genderAttribute.setValue("M");
  Element employee = document.createElement("Employee");
  employee.setAttributeNode(genderAttribute);
  employee.appendChild(firstName);
  employee.appendChild(lastName);
  return employee;
```

Interface Attr

- ☐ String getName ()
 - Název atributu
- ☐ String getValue ()
 - Hodnota atributu
- void setValue (String value)
 - Nastaví hodnotu atributu
- ☐ Element getOwnerElement ()
 - Elementový uzel, k němuž atribut přísluší
- □ TypeInfo getSchemaTypeInfo ()
 - Informace o typu atributu
- □ boolean getSpecified ()
 - true = atribut byl explicitně uveden v dokumentu
- □ boolean isld ()
 - true = atribut je typu ID

```
NamedNodeMap attrs =
  node.getAttributes();
Attr attr = (Attr)attrs.item(0);
System.out.print(
  attr.getNodeName() + "=\"" +
  attr.getNodeValue() + "\"");
```

Interface CharacterData

- ☐ String getData ()
 - Aktuální znaková data
- □ int getLength ()
 - Délka znakových dat
- String substringData (int offset, int count)
 - Podčást aktuálních dat
- void setData (String data)
 - Nastaví aktuální znaková data
- □ void insertData (int offset, String arg)
 - Přidá daný text na danou pozici
- □ void appendData (String arg)
 - Přidá daný text na konec
- □ void deleteData (int offset, int count)
 - Odstraní text v daném rozsahu
- void replaceData (int offset, int count, String arg)
 - Nahradí text v daném rozsahu

Interface Text

- Metody CharacterData
- ☐ String getWholeText ()
 - Textový obsah všech logicky sousedících textových uzlů daného uzlu spojený v jeden celek
- ☐ Text replaceWholeText (String content)
 - Nahradí textový obsah všech logicky sousedících textových uzlů daného uzlu
- boolean isElementContentWhitespace ()
 - true = textový uzel obsahuje nevýznamné bílé znaky
- ☐ Text splitText (int offset)
 - Na daném místě rozdělí textový uzel do dvou.

Interface ProcessingInstruction

- ☐ String getData ()
 - Textový obsah Pl
- □ void setData (String data)
 - Nastavení textového obsahu Pl
- ☐ String getTarget ()
 - Cíl Pl

Interface Notation

- ☐ String getPublicId ()
 - Veřejný identifikátor notace
- ☐ String getSystemId ()
 - Systémový identifikátor notace

Interface Entity

- ☐ String getNotationName ()
 - Jméno notace pro neparsované entity
- ☐ String getPublicId ()
 - Veřejný identifikátor entity
- ☐ String getSystemId ()
 - Systémový identifikátor entity
- ☐ String getXmlVersion ()
 - Specifikovaná verze externí entity
- ☐ String getXmlEncoding ()
 - Specifikované kódování externí entity
- □ String getInputEncoding ()
 - Kódování použité pro externí entitu při parsingu

Interface DocumentType

- ☐ String getName ()
 - Jméno kořenového elementu DTD
- □ String getPublicId ()
 - Veřejný identifikátor DTD
- ☐ String getSystemId ()
 - Systémový identifikátor DTD
- ☐ String getInternalSubset ()
 - Definice DTD ve formě textového řetězce
- □ NamedNodeMap getEntities ()
 - Seznam deklarovaných entit
- □ NamedNodeMap getNotations ()
 - Seznam deklarovaných notací

Další rozhraní

- □ Interface DocumentFragment
 - Pouze metody Node
- Interface EntityReference
 - Pouze metody Node
- Interface CDATASection
 - Metody Node, Text a CharacterData
- Interface Comment
 - Metody Node a CharacterData

Konec